Guía 3: Datos deportivos

En esta guía se trabajará con un dataset real de deportistas que contiene problemas típicos de datos del mundo real: valores nulos, duplicados, errores de formato y outliers.

El objetivo es aplicar técnicas de limpieza con pandas y luego realizar un análisis básico para extraer conclusiones sobre el rendimiento deportivo.

Descripción del Dataset

El archivo deportistas.csv contiene 200 registros de deportistas de distintas disciplinas. Cada fila representa a un atleta con sus datos físicos y de rendimiento.

Columna	Tipo esperado	Descripción
nombre	texto	Nombre del deportista
deporte	texto	Disciplina deportiva (con errores de mayúsculas)
edad	entero	Edad en años
peso_kg	decimal	Peso en kg (algunos valores con coma decimal)
altura_cm	entero	Altura en centímetros
frecuencia_cardiaca_bpm	entero	Frecuencia cardíaca en reposo (bpm)
horas_entrenamiento_semana	decimal	Horas de entrenamiento por semana
rendimiento_score	decimal	Puntaje de rendimiento del 1 al 10
posicion	texto	Posición en el equipo

Se solicita a partir de esta información:

Exploración inicial del DataSet

1. Determinar los problemas presentes con la información del Dataset.
2. Explorar el DataSet: cargar el csv con pandas y mostrar las 10 primeras filas.
3. Revisar los tipos de datos.
4. Contar valores nulos por columna -> isnull().sum()
5. Identificar duplicados -> duplicated().sum()

Limpieza de datos

Crea una función limpiar_deportistas(df) en src/limpieza.py que realice lo siguiente:

1. Normalizar nombres de columnas.
2. Normalizar la columna deporte, mapeando a nombres estandarizados
3. Convertir peso_kg a float, reemplazar coma por punto.
4. Convertir columnas numéricas
5. Eliminar filas duplicadas
6. Detectar y eliminar outliers en peso_kg y horas_entrenamiento usando el método IQR.
7. Imputar los valores nulos restantes con la media de cada columna numérica.

Análisis de datos

Crea funciones en src/analisis.py que realice lo siguiente:

1. Resumen_datos(df): total de deportistas, promedio de rendimiento, edad promedio
2. Promedio_por_deporte(df): promedio de rendimiento agrupado por disciplina.
3. Deportistas_destacados(df): filtrar deportistas con rendimiento_score mayor al umbral(7.0) .

Exportación

Exportar los resultados:

1. El DataFrame limpio como outputs/deportistas_limpios.csv
2. **<u>El análisis por deporte como outputs/ analisis_por_deporte.csv</u>**
3. Estructura del proyecto:

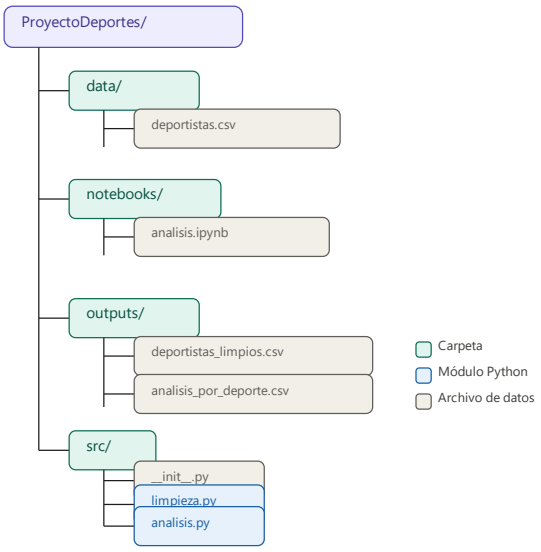

<u>Envío:</u>

Una vez finalizado, subir proyecto a github (individualmente) y enviar url de repositorio por medio de AVA.

Preparar readme con el paso a paso de lo construido y explicación clara, precisa de lo que ha efectuado.